

# 暨南大学本科实验报告专用纸(附页)

## 暨南大学本科实验报告专用纸

课程名称 数字图像处理实验 成绩评定                       
实验项目名称 利用多种分割方法的老虎前景提取 指导教师 汤知日  
实验项目编号                      实验项目类型 设计型 实验地点 教504  
学生姓名 张朋洋 学号 2022104334 学院 智能科学与工程  
工程学院 专业 物联网工程 实验时间 2024 年 11 月 20 日

### 实验目的

1. 基于图像边缘检测的方法找到老虎的前景，如果效果不好，那么就加上光影改善方法进行尝试。
2. 基于任意聚类算法的图像分割方法找到老虎前景，如果效果不好，给出分析原因。

### 实验工具

1. Python
2. cv2

### 实验内容

#### (一) 实验(方法)原理

1. K-means 聚类分割：
  - (1) 无监督的聚类算法。将图像像素分为  $K$  个不同类别(先划)，主要通过**最小化每个像素点与其所属聚类中心之间的距离**来实现图像的分割。
  - (2) 初始化中心点：首先随机选择  $K$  个中心点， $K$  是预先定义的簇的数量。
  - (3) 分配每个像素到最近的中心点：对于图像中的每个像素，根据其颜色值(或其他特征)将其分配到最近的中心点，形成  $K$  个簇。
  - (4) 更新中心点：计算每个簇中所有像素的**均值**，并将该均值作为新的中心点。
  - (5) 重复步骤 2 和 3：重复分配像素和更新中心点的过程，直到中心点不再发生变化或达到最大迭代次数。
  - (6) 图像分割：最终，每个像素所属的簇代表了图像中的一个区域。
2. Mean\_Shift
  - (1) Mean Shift 是一种基于**密度**的聚类算法，它与 K-means 聚类不同，主要通过寻找**数据的密度中心**来进行聚类，而不是依赖于指定簇的数量。
  - (2) Mean Shift 算法非常适合处理不规则形状的簇，并且**不需要预先设定簇的数量**。
  - (3) 聚类原理：

# 暨南大学本科实验报告专用纸(附页)

- ① 初始化：从数据中随机选择一个点作为起始点。
  - ② 计算窗口内的均值：围绕该点使用一个窗口（通常是圆形或球形）来计算窗口内所有点的均值（质心），即对窗口内的点进行加权平均。
  - ③ 移动点到均值：将当前点移动到计算出的均值位置。
  - ④ 重复：重复步骤 2 和 3，直到点的移动变化小于某个阈值，表示聚类中心已收敛。
3. HSV+形态学提取：
- (1) HSV (Hue、Saturation、Value) 颜色空间能更好地分离颜色信息。
  - (2) 通过设置橙色、白色、黑色的 HSV 范围，生成掩码。本实验尝试提取老虎的前景部分。
  - (3) 结合形态学操作（开运算和闭运算）进行平滑和细化，去除小噪声，改善分割质量。
  - (4) 应用掩码提取出老虎前景。
4. 自适应阈值改善分割：
- (1) 解决光影不均的情况。
  - (2) 自适应直方图均衡（CLAHE）来提高图像对比度，均衡光影影响
  - (3) 把图像分为 8x8 小图像块，分别进行直方图均衡处理
5. 频谱图改类结果图：
- (1) 在 K-means 聚类后，通过绘制频谱图，观察各个类别的像素频率分布
  - (2) 手动选择相似的类别进行合并，以便更好地将老虎的各部分融合为一个整体。
6. 手动标类法：
- (1) 利用 OpenCV 提供的鼠标回调函数手动标注图像中感兴趣的区域
  - (2) 在自动分割效果不理想时提供了一种手动干预的手段。

## （二）实验步骤：

1. K-means 聚类分割：
  - (1) 将图像数据转换为像素列表，并通过 K-means 算法分为 3 类。（分为三类的主要原因是图像主要有三类特征。方便后续合并或调整。后续其他方法也有用到）
  - (2) 根据频谱图观察各类别频率，手动合并合适的类别以提取老虎前景。
  - (3) 动标注的点，进行区域生长或合并，提取前景。
2. HSV+形态学提取：
  - (1) 将图像转换为 HSV 色彩空间。
  - (2) 设置橙色、白色和黑色的 HSV 范围，生成掩码。
  - (3) 使用形态学操作（如开运算和闭运算）去除噪声。
  - (4) 使用掩码提取老虎的前景部分。
3. 自适应阈值改善分割：
  - (1) 对原始图像应用自适应直方图均衡（CLAHE），提高对比度。
  - (2) 使用增强后的图像进行 HSV 提取或 K-means 分割，以改善分割效果。
4. 频谱图改类结果图：
  - (1) 在 K-means 聚类之后，绘制频谱图以分析各类别的频率分布。
  - (2) 根据分析结果选择相邻类别进行合并，确保各部分（如橙色毛发、黑色

# 暨南大学本科实验报告专用纸(附页)


条纹、白色区域) 均被包含。

## 5. 手动标类法:


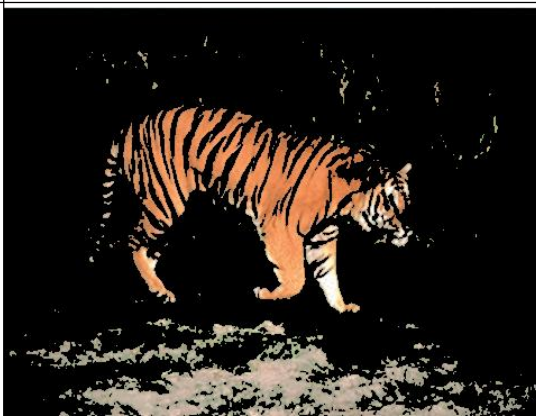
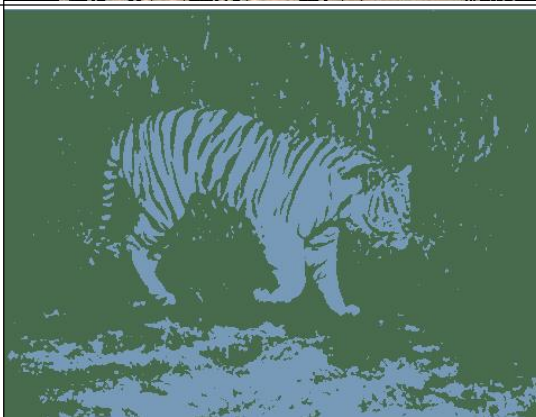
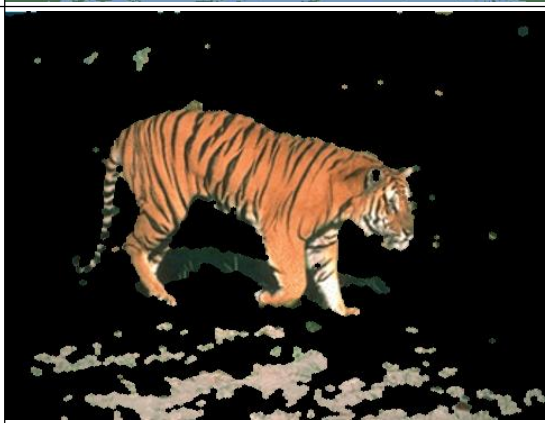
- (1) 显示原始图像, 使用鼠标回调函数在图像上进行手动标注。
- (2) 记录标注的像素点, 通过区域生长或掩码合并的方法提取前景。

## (三) 实验结果

### 1. 对比图:

方法	结果图
原图	
Canny 边缘检测	
Laplacian of Gaussian, LoG 边缘检测	

# 暨南大学本科实验报告专用纸(附页)

<p>超像素分割</p>	
<p>K-means</p>	
<p>Mean_shift</p>	
<p>HSV+形态学提取</p>	

# 暨南大学本科实验报告专用纸(附页)

自适应阈值改善分割	
频谱图改类	
手动标类	

2. 所有实验代码及相关文件已经上传到:

[GitHub:https://github.com/zmydsg/DIP.git](https://github.com/zmydsg/DIP.git)

## 实验总结

### (一) 分析

#### 1. K-means 聚类

- (1) 由于老虎黑色条纹和背景在 RGB 数值上很接近,所以在最后聚类时,这种方法会把他俩聚为一类。老虎背部的边界,因为光影更强,所有边界显得更不明显,导致比别的边界更难以识别,后续别的方法也有这种现象出现。
- (2) 通过调整参数,直方图均衡手段也没有很好的解决效果。光影消除的调节手段有限,需要采用其他手段进行干涉,所以我选了后面这些方法。

# 暨南大学本科实验报告专用纸(附页)

- (3) 色彩复杂：老虎的毛皮包括橙色、白色、黑色等多种颜色，并且这些颜色有较高的空间频率，K-means 可能无法准确区分这些复杂的颜色组合。
- (4) 类间相似度高：老虎的某些区域（如橙色毛发和黄色背景）在颜色上可能较为相似，导致聚类时被错误分为同一类。
- (5) 类别选择问题：K 值的选择对结果有很大影响，错误的 K 值可能导致前景和背景未能正确分开，导致部分老虎区域被错误分类到背景中。

## 2. Mean\_shift

### (1) 优点：

不需要预先指定簇的数量。

对噪声比较鲁棒。

适合处理复杂形状的簇，能够找到密度较高的区域。

### (2) 缺点：

计算复杂度较高，尤其是在处理大图像时。需要选择合适的空间和颜色半径，调参可能比较困难。针对离群值表现不是太好。

## 3. HSV + 形态学处理提取

- (1) 颜色范围设定不准确：橙色、白色、黑色等颜色范围如果设定不准确，可能会导致部分老虎前景没有被提取出来。例如，橙色的范围过窄会漏掉部分橙色毛发，而黑色范围不够准确会导致黑色条纹（如尾巴）未能被完全提取。
- (2) 光影影响：光影差异会影响 HSV 提取效果，如果老虎身上的光照不均匀，可能导致某些区域的颜色值偏离预设的 HSV 范围，进而未被提取出来。
- (3) 形态学操作参数不当：形态学的开闭操作用于去除噪声和填补小空洞，但如果参数不当，可能会引入伪影，导致部分前景丢失或背景引入。

## 4. 自适应阈值改善分割

- (1) 过度增强：CLAHE 增强图像对比度时，可能会过度增强某些区域的噪声，使得分割时噪声也被包含在前景中。
- (2) 光照复杂性：老虎图像中的光影复杂度较高，增强对比度并不能完全消除这些光影问题，依然会影响后续的分割操作。
- (3) 颜色分布不均：即使对比度增强了，老虎的颜色仍然存在复杂的分布，尤其是在边缘部分，导致分割线可能不精确，影响分割效果。

## 5. 频谱图辅助类别合并

- (1) 类别频率不一致：在某些情况下，不同类别的像素数量相差很大，合并类别后可能导致前景区域和背景区域的混杂。

## 6. 手动标类法

- (1) 标注不完整：如果手动标注点选择不准确或者覆盖不足，可能导致分割不完整，某些区域未能正确标记为前景。
- (2) 标注的主观性：手动标不是很精准落点在目的标定点。

## (二) 结论

1. 针对老虎前景提取，使用了多种方法，包括 K-means 聚类分割、HSV 颜色提取、自适应阈值改善等。主要是为了消除老虎条纹与毛色差异过大而对整体



# 暨南大学本科实验报告专用纸(附页)

提取效果的影响。通过组合不同的方法，大幅度减小了图像中光影变化的影响、老虎相邻位置颜色差异过大的影响。不同方法最终效果也不尽相同，各有优劣。

## 2. K-means 聚类

原理：K-means 是一种基于划分的聚类算法，它通过迭代过程将数据点分配到 K 个簇中，使得每个簇内的点到簇中心的距离最小。K-means 假设数据集可以被划分为 K 个球形簇。

关键步骤：

初始化中心点：随机选择 K 个中心点，作为簇的初始中心。

分配簇：对于每个数据点，计算其与 K 个中心点的距离，并将该点分配到距离最小的中心点对应的簇中。

更新中心点：计算每个簇中所有点的均值，将该均值作为新的簇中心。

重复步骤 2 和 3：直到中心点的变化小于设定的阈值（或达到最大迭代次数）。

优缺点：

优点：计算速度较快，适合大数据集。

缺点：需要预先指定簇的数量 K，容易受到初始值的影响，且对于非球形簇效果较差。

## 3. Mean Shift 聚类

原理：Mean Shift 是一种基于密度的聚类算法，它通过不断地移动数据点到数据的密度峰值区域，来找到高密度区域，并将这些区域视为一个簇。Mean Shift 不需要预先指定簇的数量，适合处理任意形状的簇。

关键步骤：

初始化：从数据中选择一个随机点作为当前点。

计算均值（质心）：在一个给定半径的窗口内，计算窗口内所有点的均值。

移动点到均值：将当前点移动到计算出的均值位置（即质心）。

重复步骤 2 和 3：直到点的移动变化小于设定的阈值，表明该点已收敛到密度最大值区域。

簇分配：将收敛的点作为簇的中心，所有在该点附近的点被分配到该簇中。

优缺点：

优点：

不需要预先指定簇的数量。

能够找到任意形状的簇，不受簇形状的限制。

对噪声具有较强的鲁棒性。

缺点：

计算复杂度较高，尤其是在处理大数据集时。

需要选择合适的窗口大小（空间半径）和带宽参数（颜色半径）。

## 4. 主要区别：

K-means 是基于距离的划分方法，要求簇的形状是球形的，并且需要预先指定簇的数量 K；而 Mean Shift 是基于密度的聚类方法，不需要预先指定簇的数量，适合处理复杂形状的簇。

K-means 在聚类过程中使用中心点和最小化欧氏距离的策略，而 Mean Shift 通过寻找数据的密度中心（局部均值）来聚类。

总的来说，K-means 适合处理簇的形状比较规则且数据量较大的情况，而 Mean Shift 更适用于簇形状复杂且数据点分布不均的场景。